Classificação de Biópsia de Câncer de Mama

Transfer Learning com ResNet-18 | PyTorch

1. Visão Geral

Este notebook implementa um classificador de imagens de biópsia de câncer de mama usando Transfer Learning com a arquitetura ResNet-18 pré-treinada no ImageNet. O objetivo é distinguir entre amostras benignas e malignas a partir do dataset Breast Cancer Biopsy (7.500 imagens).

2. Configuração do Ambiente

2.1 Instalação de Dependências

Instalação das bibliotecas PyTorch e TorchVision:

```
!pip install torch torchvision
```

2.2 Importações

Importação dos módulos necessários:

```
import torch
import torch.nn as nn
import torch.optim as optim
from torchvision import datasets, transforms, models
from torchvision.models import ResNet18_Weights
from torch.utils.data import DataLoader
from google.colab import drive
```

3. Pré-processamento das Imagens

As imagens passam por três transformações antes de entrar na rede:

```
transform = transforms.Compose([
    transforms.Resize((224, 224)),
    transforms.ToTensor(),
    transforms.Normalize(mean=[0.5, 0.5, 0.5], std=[0.5, 0.5, 0.5])
])
```

Transformação	Parâmetros	Finalidade

`Resize`	`224 × 224 px`	Adequar ao tamanho esperado pelo ResNet-18
`ToTensor`	—	Converter pixels de [0,255] para [0.0, 1.0]
`Normalize`	`mean=0.5, std=0.5`	Escalar valores para o intervalo [-1, +1]

4. Carregamento e Divisão do Dataset

O dataset é carregado via ImageFolder, que interpreta automaticamente cada subpasta como uma classe (benign / malignant). Os dados são divididos em 80% treino e 20% teste:

```
full_dataset = datasets.ImageFolder(root=dataset_dir, transform=transform)

train_size = int(0.8 * len(full_dataset))
test_size  = len(full_dataset) - train_size
train_dataset, test_dataset = torch.utils.data.random_split(
    full_dataset, [train_size, test_size]
)

train_loader = DataLoader(train_dataset, batch_size=32, shuffle=True)
test_loader  = DataLoader(test_dataset,  batch_size=32, shuffle=False)
```

Dataset utilizado: Breast Cancer Biopsy 7500 — disponível em:
https://drive.google.com/drive/folders/1HSjQ5INhzDQIQAlt7C644uj7lvwD3mHa

5. Arquitetura do Modelo — ResNet-18

A ResNet-18 é carregada com pesos pré-treinados no ImageNet. Apenas a camada totalmente conectada (fc) é substituída para produzir 2 saídas (benigno / maligno):

```
device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')

modelo = models.resnet18(weights=ResNet18_Weights.DEFAULT)
num_features = modelo.fc.in_features
modelo.fc = nn.Linear(num_features, 2)   # 2 classes: benigno / maligno
modelo = modelo.to(device)
```

Estrutura resumida da ResNet-18:

Bloco	Camadas	Descrição
Conv inicial	1 camada	Conv 7×7, BatchNorm, ReLU, MaxPool
Layer 1–4	16 camadas	4 grupos de blocos residuais (BasicBlock)

FC (modificada)	1 camada	Linear(512 → 2) para classificação binária

6. Treinamento

O modelo é treinado por 5 épocas usando a função de perda CrossEntropyLoss e o otimizador Adam com taxa de aprendizado 0.001:

```
criterio   = nn.CrossEntropyLoss()
otimizador = optim.Adam(modelo.parameters(), lr=0.001)

for epoch in range(5):
    modelo.train()
    perda, corretos, total = 0.0, 0, 0

    for images, labels in train_loader:
        images, labels = images.to(device), labels.to(device)
        otimizador.zero_grad()
        prediction = modelo(images)
        loss = criterio(prediction, labels)
        loss.backward()
        otimizador.step()

        perda += loss.item()
        _, predicted_classes = torch.max(prediction, 1)
        corretos += (predicted_classes == labels).sum().item()
        total   += labels.size(0)

    print(f'Epoch {epoch+1}, Erro: {perda/len(train_loader):.4f},
           Acuracia: {corretos/total:.2%}')
```

6.1 Resultados por Época

Métricas registradas durante o treinamento:

Época	Erro Médio	Acurácia Treino
1	0.2845	**88.53%**
2	0.1534	**94.12%**
3	0.1212	**95.62%**
4	0.1107	**96.02%**
5	0.0716	**97.37%**

7. Avaliação no Conjunto de Teste

Após o treinamento, o modelo é avaliado no conjunto de teste (20% dos dados) sem atualização de gradientes:

```
modelo.eval()
corretos, total = 0, 0

with torch.no_grad():
    for images, labels in test_loader:
        images, labels = images.to(device), labels.to(device)
        prediction  = modelo(images)
        _, predicted = torch.max(prediction.data, 1)
        corretos += (predicted == labels).sum().item()
        total    += labels.size(0)

print('Acuracia no conjunto de teste:', 100 * corretos / total)
```

7.1 Resultado Final

Acurácia no Conjunto de Teste	86.94%

O modelo atingiu aproximadamente 86,94% de acurácia no conjunto de teste, demonstrando que o Transfer Learning com ResNet-18 é eficaz para classificação de biópsias mesmo com um número moderado de épocas.

8. Resumo da Pipeline

Etapa	Detalhe
Dataset	Breast Cancer Biopsy 7.500 imagens | classes: benign / malignant
Divisão	80% treino (6.000) / 20% teste (1.500)
Pré-processamento	Resize 224×224 → ToTensor → Normalize(0.5, 0.5)
Modelo base	ResNet-18 com pesos ImageNet (Transfer Learning)
Fine-tuning	Substituição da camada FC: Linear(512 → 2)
Otimizador	Adam | lr=0.001
Função de perda	CrossEntropyLoss
Épocas	5 | batch_size=32
Acurácia treino (ep.5)	97.37%
Acurácia teste	86.94%