Tech Challenge — Fase 1

Classificação de Câncer de Mama com Machine Learning

Random Forest vs. KNN | Dataset UCI — Wisconsin Diagnostic

1. Definição do Problema e Planejamento

O diagnóstico de câncer de mama a partir de biópsias envolve a análise visual de características dos núcleos celulares como tamanho, forma e irregularidade do contorno. Esse processo é trabalhoso, sujeito a variações entre diferentes profissionais e exige especialização.

A pergunta que motivou este trabalho foi: é possível ensinar um programa de computador a identificar padrões que separam tumores benignos de malignos com a mesma confiabilidade de um especialista?

Para responder a isso, utilizamos um conjunto de dados com 569 biópsias reais, cada uma descrita por 30 características celulares medidas em laboratório. Desses casos, 357 eram benignos e 212 malignos. Dois modelos foram treinados e comparados: Random Forest e KNN.

2. Coleta e Entendimento dos Dados

2.1 Informações do Dataset

Para treinamento e validação do modelo, utilizamos o dataset disponibilizado pela Universidade da Califórnia Irvine (UCI) — Breast Cancer Wisconsin (Diagnostic).Arquivo: https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic

Além do campo ID (identificador da amostra) e do target diagnosis (diagnóstico), o dataset possui as seguintes características:

Característica do Núcleo Celular	Significado
radius	Média da distância do centro ao perímetro do núcleo
texture	Variação nos níveis de cinza da imagem
perimeter	Comprimento do contorno do núcleo
area	Área total do núcleo
smoothness	Variação local no comprimento do raio
compactness	Relação perímetro² / área − 1
concavity	Severidade das porções côncavas do contorno
concave points	Número de pontos côncavos no contorno
symmetry	Simetria do núcleo
fractal dimension	("aproximação do contorno" − 1)

Cada característica do núcleo celular aparece em três versões:

- _mean — média dos valores
- _se — erro padrão da média (standard error). Demonstra o quão confiável é a média.
- _worst — maior valor observado

3. Análise dos Dados

3.1 Importações e Carregamento

```
import numpy as np
import pandas as pd
import seaborn as sns
import shap
import matplotlib.pyplot as plt
from sklearn.decomposition import PCA
from sklearn.pipeline import Pipeline
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import LabelEncoder, StandardScaler
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import train_test_split
from sklearn.metrics import (accuracy_score, f1_score, classification_report,
                             confusion_matrix, recall_score, precision_score,
                             roc_auc_score, roc_curve)
from sklearn.neighbors import KNeighborsClassifier

df = pd.read_csv("data.csv", sep=",")
```

3.2 Inspeção Inicial

```
print(df.shape[0], "linhas")
print(df.shape[1], "colunas")
569 linhas
33 colunas
```

Analisando as colunas constatamos que:

- A única coluna descritiva é o nosso target diagnosis.
- Quase todos os campos possuem 569 ocorrências de dados non-null, o que já indica que não há colunas nulas, exceto a coluna Unnamed.

O campo Unnamed possui todas as linhas nulas, o que indica ser uma má formação no dataset. Sendo assim, foi excluído:

```
# Verificando campos nulos
df.isnull().sum()

# Excluindo a coluna vazia
if 'Unnamed: 32' in df.columns:
    df.drop('Unnamed: 32', axis=1, inplace=True)
```

Confirmamos que 'Unnamed: 32' é o único campo com valores nulos e que a quantidade de registros nulos é igual ao total de registros do dataset.

3.3 Distribuição das Classes

```
df['diagnosis'].value_counts(normalize=True).mul(100).round(2).astype(str) + ' %'
```

Os únicos valores na coluna diagnosis são B (Benigno) e M (Maligno), aderente à documentação do dataset. A distribuição aproximada é:

- Benigno (B): ~62,7% — 357 casos
- Maligno (M): ~37,3% — 212 casos

3.4 Análise Descritiva

Nota-se uma diferença nas escalas dos dados. Por exemplo, area_mean varia entre 143.5 e 2.501, enquanto fractal_dimension_mean varia entre 0.04996 e 0.09744.

Análise dos histogramas: algumas variáveis estão bem distribuídas, aproximando-se de uma distribuição gaussiana (normal). Porém, outras apresentam distribuição assimétrica (skew positivo), o que pode indicar a presença de outliers.

Análise dos boxplots: praticamente todos os campos, exceto concave_points_worst, possuem outliers. Porém, no contexto de diagnóstico baseado em características de núcleos celulares, é esperado que existam valores extremos — removê-los poderia comprometer sinais importantes para detecção de tumores malignos. Portanto, o dataset foi mantido com os outliers.

A análise do heatmap de correlação revelou alta correlação entre variáveis do mesmo grupo (ex.: radius_mean, perimeter_mean e area_mean), o que é esperado dada a relação geométrica entre elas.

4. Preparação dos Dados

As features foram separadas do target e a variável categórica diagnosis foi transformada em numérica usando LabelEncoder:

```
# Separando features do target
X = df.drop(columns=['id', 'diagnosis'])
y = df['diagnosis']

# Transformando target categórico em numérico (B=0, M=1)
y = LabelEncoder().fit_transform(y)

# Divisão treino/teste com stratify para manter proporção de classes
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=df['diagnosis']
)
```

O stratify garante que a proporção de benignos/malignos seja mantida tanto no treino quanto no teste. O pré-processamento com StandardScaler é aplicado via pipeline para padronizar todas as variáveis numéricas na mesma escala.

5. Modelagem

5.1 Random Forest Classifier

O Random Forest combina múltiplas árvores de decisão para reduzir overfitting e melhorar a generalização. Cada árvore é treinada em um subconjunto aleatório dos dados e das features.

```
random_forest_pipeline = Pipeline([
    ('preprocessorScaler', ColumnTransformer([
        ('num', StandardScaler(), X.columns)
    ])),
    ('randomForest', RandomForestClassifier(
        n_estimators=100,   # número de árvores
        random_state=42,    # reprodutibilidade
        n_jobs=-1           # usa todos os núcleos disponíveis
    ))
])

random_forest_pipeline.fit(X_train, y_train)
y_pred_random = random_forest_pipeline.predict(X_test)
y_prob_random = random_forest_pipeline.predict_proba(X_test)[:, 1]
```

Resultados do Random Forest:

```
Acurácia: 0.9737
F1-score: 0.9630

Relatório de classificação:
              precision    recall  f1-score   support
           0       0.96      1.00      0.98        72
           1       1.00      0.93      0.96        42
    accuracy                           0.97       114
   macro avg       0.98      0.96      0.97       114
weighted avg       0.97      0.97      0.97       114
```

5.2 K-Nearest Neighbors (KNN)

O KNN classifica cada amostra com base nos k vizinhos mais próximos no espaço de features. É um algoritmo simples, sem fase de treinamento explícita (lazy learner), sensível à escala das variáveis — por isso o StandardScaler é aplicado antes.

```
knn_pipeline = Pipeline([
    ('scaler', StandardScaler()),
    ('knn', KNeighborsClassifier(n_neighbors=3))
])

knn_pipeline.fit(X_train, y_train)
```

```
y_pred_knn  = knn_pipeline.predict(X_test)
y_prob_knn  = knn_pipeline.predict_proba(X_test)[:, 1]
```

Resultados do KNN (k=3):

```
Acurácia: 0.9386
F1-score: 0.9322

Relatório de classificação:
              precision    recall  f1-score   support
           0       0.92      0.99      0.95        72
           1       0.97      0.86      0.91        42
    accuracy                           0.94       114
   macro avg       0.94      0.93      0.93       114
weighted avg       0.94      0.94      0.94       114
```

6. Avaliação

6.1 Métricas e Critérios de Avaliação

Os modelos foram avaliados no conjunto de teste (20% dos dados, com stratify para manter a proporção de classes). As métricas utilizadas foram:

Métrica	Definição	Importância no Contexto
Acurácia	Proporção de predições corretas	Visão geral útil, mas insuficiente se isolada
Recall (Sensibilidade)	TP / (TP + FN) — malignos corretamente detectados	MÉTRICA MAIS CRÍTICA: FN = não detectar câncer = risco de vida
Precisão	TP / (TP + FP) — dos classificados como malignos, quantos realmente são	Importante, mas clinicamente menos grave que o FN
F1-Score	Média harmônica entre Precision e Recall	Equilíbrio geral entre precisão e sensibilidade
ROC-AUC	Área sob a curva ROC	Mede a capacidade discriminativa global do modelo

6.2 Comparação dos Modelos

Em termos práticos, o Random Forest errou em menos de 3 casos a cada 100. O KNN errou em aproximadamente 6 a cada 100. Ambos os desempenhos são expressivos, mas o tipo de erro importa mais do que o número geral:

- Falso Negativo (FN) — dizer que um tumor é benigno quando na verdade é maligno: ERRO MAIS GRAVE. O paciente pode não receber tratamento a tempo.
- Falso Positivo (FP) — dizer que um tumor é maligno quando na verdade é benigno: gera preocupação desnecessária e exames extras, mas não coloca vidas em risco imediato.

Métrica	Random Forest	KNN (k=3)
Acurácia	97.37%	93.86%
Recall (Maligno)	93%	86%
Precisão (Maligno)	100%	97%
F1-Score	96.30%	93.22%
ROC-AUC	~0.9985	~0.9700

Comparando as matrizes de confusão e a curva ROC, observamos diferença clinicamente relevante entre os modelos. Em um hospital que analisa mil biópsias por mês, a diferença entre ~4% e ~6% de casos malignos não detectados representa dezenas de pacientes. Por isso, o Random Forest é o modelo recomendado para este contexto.

7. Interpretabilidade: Feature Importance e SHAP

7.1 Feature Importance — Random Forest

O Random Forest fornece nativamente feature_importances_, que mede a redução média de impureza (Gini) atribuída a cada feature ao longo de todas as árvores.

```
rf_model = random_forest_pipeline.named_steps['randomForest']
importances = pd.Series(rf_model.feature_importances_, index=X.columns)
importances_sorted = importances.sort_values(ascending=False)
```

Top 10 características por importância (Feature Importance):

Característica	Importância
area_worst	0.1514
concave points_worst	0.1265
radius_worst	0.0935
perimeter_worst	0.0836
concave points_mean	0.0811
perimeter_mean	0.0771
radius_mean	~0.06
concavity_worst	~0.05
texture_worst	~0.04
area_mean	~0.04

7.2 SHAP — SHapley Additive exPlanations

O SHAP é baseado na teoria dos jogos cooperativos (valores de Shapley) e oferece vantagens sobre a Feature Importance: direção do efeito e explicação por amostra. Foi utilizado TreeExplainer, otimizado para modelos baseados em árvores.

```
X_test_scaled =
random_forest_pipeline.named_steps['preprocessorScaler'].transform(X_test)
X_test_scaled_df = pd.DataFrame(X_test_scaled, columns=X.columns)

explainer = shap.TreeExplainer(rf_model)
shap_values = explainer.shap_values(X_test_scaled_df)
# shap_values[1] = valores SHAP para a classe Maligno
shap_maligno = shap_values[1]
Forma dos valores SHAP: (114, 30)
SHAP calculado para a classe Maligno (1)
```

```
# Análise de caso individual: primeiro caso maligno do conjunto de teste
idx_maligno = np.where(y_test == 1)[0][0]
print(f'Amostra #{idx_maligno} | Real: Maligno | Previsto: Maligno')

# Feature mais importante
top_feature = importances.idxmax()  # area_worst
Amostra #1 | Real: Maligno | Previsto: Maligno
Feature mais importante: area_worst
```

7.3 Conclusões da Interpretabilidade

De acordo com os dados obtidos e os gráficos de Feature Importance e SHAP, ambas as técnicas são convergentes: as características com _worst dominam em ambas as análises.

- Características extremas de núcleos celulares (valor máximo observado) são mais diagnósticas do que médias, pois uma única célula atípica pode sinalizar malignidade.
- concave_points_worst, perimeter_worst e radius_worst são consistentemente as mais relevantes.
- O SHAP adiciona direção: pontos vermelhos (valores altos) à direita no Summary Plot confirmam que valores altos dessas features aumentam a probabilidade de classificação como Maligno.
- Candidatas à redução de dimensionalidade por apresentarem valores baixos: texture_se e fractal_dimension_mean. Essas características poderiam ser removidas sem impacto significativo no desempenho.

8. Uso na Prática

Os resultados mostram que o modelo tem desempenho suficiente para ser útil em um contexto clínico real, porém não como substituto do diagnóstico médico — e sim de forma complementar/auxiliar. O modelo funciona como um assistente experiente que analisou várias biópsias e aprendeu a reconhecer padrões: pode sinalizar riscos, priorizar casos urgentes e oferecer uma segunda opinião, mas a decisão final sempre cabe ao médico.

8.1 Potencial de Uso

Aplicação	Descrição
Triagem	Sinalizar automaticamente casos com maior probabilidade de malignidade, priorizando-os na fila de análise médica
Opinião computacional	Em casos limítrofes, fornecer perspectiva adicional baseada em padrões estatísticos
Redução de variabilidade	Diagnósticos por análise visual sofrem variabilidade inter-observador; o modelo padroniza o processo

8.2 Próximas Etapas

Apesar dos resultados interessantes, ainda há etapas importantes antes de qualquer implantação:

- Validação com novos pacientes: o modelo foi avaliado com dados do mesmo estudo que gerou o conjunto de treinamento. Antes do uso real, seria necessário testá-lo com biópsias de outros hospitais, equipamentos e populações.
- Incorporação de mais informações clínicas: atualmente, o modelo considera apenas características celulares. Integrar informações como idade da paciente, histórico familiar e resultado de mamografia tornaria as previsões mais completas.
- Aprovação regulatória: no Brasil, qualquer software com finalidade diagnóstica precisa de aprovação da ANVISA antes de ser utilizado em ambiente hospitalar.

O modelo vem como mais uma ferramenta de apoio para auxiliar os médicos no seu dia a dia, potencializado por novas tecnologias como o uso de inteligência artificial.

9. Resumo Executivo

Item	Detalhe
Dataset	UCI — Breast Cancer Wisconsin Diagnostic | 569 amostras | 30 features
Distribuição	357 benignos (62,7%) | 212 malignos (37,3%)
Divisão	80% treino / 20% teste com stratify
Pré-processamento	StandardScaler via Pipeline | remoção de coluna vazia
Modelo recomendado	Random Forest (n_estimators=100)
Acurácia — RF	97.37%
Recall Maligno — RF	93%
F1-Score — RF	96.30%

Acurácia — KNN (k=3)	93.86%
Recall Maligno — KNN	86%
F1-Score — KNN	93.22%
Feature mais importante	area_worst (0.1514)
Interpretabilidade	Feature Importance + SHAP (TreeExplainer)
Uso recomendado	Ferramenta de apoio clínico (triagem / 2ª opinião)